

InsurMinds — Projeto Final

Plataforma Inteligente para Análise e Comparação de Apólices D&O;

Relatório Técnico

Grupo InsurTech Minds

Ednardo Pinheiro Peixoto — Representante e Engenheiro de IA/IoT/Tech Líder

Glenda dos Santos Tavares — Atuária

Sueli Da Hora Moreira — Analytics Engineer

Rafael Torres Lattaro Soares — Especialista em Seguros

Instituto de Inteligência Artificial Aplicada — I2A2

1. Objetivo

Este documento descreve a solução desenvolvida pelo grupo InsurTech Minds para o Projeto Final do InsurMinds: uma plataforma inteligente capaz de extrair, estruturar e comparar informações de apólices de seguro D&O; (Directors and Officers), consolidando as competências trabalhadas ao longo dos Desafios 3, 4 e 5 — Machine Learning, agentes inteligentes e IA Generativa — em uma solução única aplicada ao mercado de seguros.

2. Contexto

Apólices de seguro D&O; são documentos longos e redigidos em linguagem jurídica densa. Compará-las exige identificar cláusulas, coberturas, exclusões, franquias e limites de responsabilidade — um processo que normalmente demanda várias horas de trabalho de um especialista. A solução aqui descrita automatiza grande parte desse processo utilizando OCR, agentes inteligentes e Inteligência Artificial Generativa, apoiando (sem substituir) a tomada de decisão do corretor ou analista.

3. Arquitetura da solução (multiagente)

A solução foi estruturada em 4 agentes especializados, cada um implementado como um módulo Python independente em `src/`, orquestrados por uma interface Streamlit com duas abas (Upload/Extração e Comparação):

- **Agente 1 — ExtratorDocumentoAgent** (`extraction_agent.py`): extrai o texto do PDF em duas camadas — extração direta via `pdfplumber` (usada na grande maioria dos casos, já que apólices costumam ser PDFs de texto nativo) e, apenas como fallback quando o texto extraído é insuficiente, OCR via Tesseract (`pytesseract + pdf2image`), cobrindo o requisito de leitura de documentos em PDF ou imagem.
- **Agente 2 — EstruturadorApoliceAgent** (`structuring_agent.py`): usa um LLM (Google Gemini) para interpretar o texto da apólice e estruturá-lo em um JSON padronizado (seguradora, tomador, vigência, limite máximo de garantia, franquia, coberturas básicas, extensões de cobertura, principais exclusões, âmbito geográfico e prazo complementar). O prompt fornece um modelo literal de JSON a ser preenchido (não apenas uma descrição em prosa), o que se mostrou necessário: em testes iniciais, o modelo por vezes "traduzia" os nomes dos campos por conta própria; fornecer o esqueleto exato eliminou esse comportamento.
- **Agente 3 — ArmazenamentoAgent** (`storage_agent.py`): persiste os dados extraídos em um banco SQLite local, permitindo consultar e comparar apólices já processadas sem reprocessar o documento original.
- **Agente 4 — ComparadorApoliceAgent** (`comparison_agent.py`): compara duas apólices em duas camadas — uma tabela determinística campo a campo (sem uso de LLM, garantindo que a comparação seja sempre auditável e reproduzível) e um resumo comparativo em linguagem natural gerado por IA, destacando diferenças relevantes e um perfil de risco recomendado para cada apólice.

Fluxo de funcionamento: recebimento do documento (upload) → extração do texto (Agente 1) → estruturação via IA (Agente 2) → armazenamento (Agente 3) → seleção de duas apólices já processadas → comparação (Agente 4) → apresentação dos resultados ao usuário, cobrindo as 7 etapas sugeridas pelo edital.

4. Tecnologias utilizadas

- Python 3.10+
- Streamlit — interface única com abas de upload/extração e comparação
- **pdfplumber** — extração de texto nativo de PDF
- **Tesseract OCR** (via pytesseract + pdf2image) — fallback para documentos escaneados
- LangChain + **Google Gemini** (gratuito) — estruturação e comparação via IA Generativa; também suporta Ollama (local/gratuito), Claude e GPT (pagos), configurável por variável de ambiente
- **SQLite** — armazenamento estruturado, via biblioteca padrão do Python

5. Fontes de dados utilizadas

Como o edital não disponibiliza apólices reais (documentos sigilosos), foram utilizadas condições gerais de apólices D&O; públicas, publicadas pelas próprias seguradoras, para desenvolvimento e testes:

- Allianz Seguros S.A. — Condições Gerais D&O; (documento DG0064)
- Berkley International do Brasil Seguros S.A. — Condições Gerais D&O; (documento CG_DEO)

Ambos os documentos são públicos, disponibilizados pelas seguradoras em seus sites institucionais, e foram usados exclusivamente para validar a extração, estruturação e comparação da solução.

6. Execução real e evidências

A aplicação foi executada de ponta a ponta com as duas apólices de exemplo (Allianz e Berkley). Trecho da tabela comparativa gerada automaticamente pelo Agente 4:

Seguradora: Allianz — Allianz Seguros S.A | Berkley — Berkley International do Brasil Seguros S.A.

Âmbito Geográfico: Allianz — Mundial | Berkley — Mundial, exceto Estados Unidos, Canadá, Irã e Cuba

Prazo Complementar: Allianz — 36 meses | Berkley — 12 meses (automático)

Extensões de Cobertura: Allianz — 25 extensões especiais, incluindo Mercado de Capitais | Berkley — 13 extensões, com destaque para responsabilidade trabalhista, tributária e previdenciária

Resumo comparativo gerado pelo Agente 4 (IA Generativa), na íntegra:

"A Apólice 1 (Allianz) oferece um âmbito geográfico mundial irrestrito e um prazo complementar robusto de 36 meses, enquanto a Apólice 2 (Berkley) restringe a abrangência geográfica ao excluir Estados Unidos, Canadá, Irã e Cuba, além de prever um prazo complementar menor, de 12 meses. [...] Portanto, a Apólice 1 tende a ser mais adequada para empresas com exposição internacional ampla (incluindo EUA e Canadá) e necessidade de uma pós-vigência estendida para o futuro. Por outro lado, a Apólice 2 se insere melhor em perfis de risco focados no mercado nacional [...]."

Esse resultado confirma que o sistema extrai corretamente informações específicas de cada documento (inclusive o nome oficial da seguradora, presente apenas no glossário de definições do texto) e produz uma análise comparativa coerente com o conteúdo real das apólices — sem inventar dados que não constam nos documentos (ex.: campos de valores concretos de franquia/limite, presentes apenas na Especificação da Apólice — um documento à parte, não incluído nas Condições Gerais — foram

corretamente reportados como "não informado" em vez de preenchidos com valores fictícios).

7. Requisitos mínimos atendidos

- Permitir a leitura de documentos em formato PDF ou imagem. ✓ (extração direta + OCR fallback)
- Extrair automaticamente informações relevantes das apólices. ✓
- Estruturar os dados extraídos em um formato organizado. ✓ (JSON padronizado + SQLite)
- Permitir a comparação entre pelo menos duas apólices. ✓
- Apresentar ao usuário as principais diferenças identificadas. ✓ (tabela + resumo em IA)
- Utilizar pelo menos um modelo de IA Generativa durante o processamento. ✓ (Google Gemini)
- Disponibilizar uma interface que permita demonstrar o funcionamento da solução. ✓ (Streamlit)

8. Limitações conhecidas e possibilidades de evolução

- A extração via LLM depende da qualidade e do comprimento do texto de entrada; documentos com glossários muito extensos exigem um limite de contexto generoso (ajustado para 200.000 caracteres após testes) para não perder informações que aparecem tarde no documento.
- Valores como Limite Máximo de Garantia e Franquia costumam constar apenas na "Especificação da Apólice" — um documento específico de cada contratação, separado das Condições Gerais — e portanto não estão disponíveis nos documentos públicos usados como exemplo; nesses casos o sistema reporta corretamente "não informado" em vez de inventar valores.
- O OCR (fallback) tem menor precisão que a extração direta em documentos escaneados de baixa qualidade.
- Evolução natural: suportar comparação simultânea de mais de 2 apólices, exportar o resultado em PDF/Word, cache de estruturação para não reprocessar o mesmo documento, e histórico de comparações.

9. Entregáveis desta submissão

- Este relatório técnico em PDF.
- Repositório público no GitHub, com código-fonte completo, README com instruções de instalação/execução, tecnologias, integrantes e licença MIT, incluindo a pasta `Projeto_Final_Artefatos/` com o Pitch Deck e o vídeo de demonstração.
- Arquivo ZIP contendo todo o código-fonte.
- Pitch Deck (`InsurMinds_Projeto_Final.pptx`).
- Vídeo de demonstração de até 5 minutos (`InsurMinds_Projeto_Final.mp4`).